Transformer 架构导读

Glint 瞳问演示文档 · 用于练习看词提问

摘要：本文用中文梳理 Transformer 的核心设计。它放弃了循环结构，完全依靠 attention 建模序列中的依赖关系，因此可以并行训练，也更容易捕捉长距离依赖。文中保留了常见英文术语，读到不熟悉的单词时，可以直接看着它提问。

1 为什么要离开循环网络

循环神经网络按时间步依次处理序列，后一步必须等前一步算完，这个顺序限制使并行化（parallelization）十分困难。序列一长，较早位置的信息还要穿过许多步才能传到后面，模型容易遗忘，训练时也容易出现梯度消失（vanishing gradient）。

Transformer 的思路是让每个位置直接查看所有其他位置。任意两个位置之间的连接只隔一步，长距离依赖不再需要逐步传递，这也是它名声最大的贡献。

2 缩放点积注意力

注意力的输入是 query、key 和 value 三组向量。模型用 query 与每个 key 计算相似度，归一化后得到权重，再对 value 做加权求和：

$$\mathit{Attention}(Q, K, V) = \mathit{softmax}(QK^{T} / \sqrt{d_k})\, V$$

除以 $\sqrt{d_k}$ 是一个看似微小却很关键的细节。当维度较大时，点积的方差随之变大，softmax 会被推入饱和区，梯度变得极小。这种缩放（scaling）让训练保持稳定。

3 多头注意力

单组注意力只能得到一种加权方式。多头注意力（multi-head attention）把向量线性投影成多份，在不同的表示子空间里分别计算，最后拼接（concatenate）起来。原始论文使用 8 个头，每个头的维度是 64，总计算量与单头相近。

4 位置编码

注意力本身不关心顺序，打乱输入后，每个位置得到的结果只是跟着调换。为了补上顺序信息，模型把位置编码（positional encoding）加到词向量上。原始论文采用不同频率的正弦和余弦函数，这种设计是确定性的（deterministic），不需要训练参数。

5 编码器与解码器

编码器（encoder）和解码器（decoder）各由 6 层堆叠而成。每层都包含注意力和前馈网络（feed-forward network），并配有残差连接（residual connection）与层归一化（layer

normalization）。解码器还多一层交叉注意力，并用掩码（mask）遮住未来的位置，防止模型在预测时提前看到答案。

超参数	原始论文取值
模型维度 d_{model}	512
注意力头数 h	8
堆叠层数 N	6
前馈层维度 d_{ff}	2048

6 影响

Transformer 最初面向机器翻译，在 WMT 2014 英德任务上取得了 28.4 的 BLEU 分数，同时大幅缩短了训练时间。此后，这套架构成为大语言模型的基础。理解了 attention 这一个机制，后续许多模型的设计都会变得容易看懂。

参考文献

Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need. NeurIPS, 2017. arXiv:1706.03762.